# Al Lista 4 - Problem klasyfikacji szkła

# Zuzanna Sikorska, 260464

Zbiór danych: https://archive.ics.uci.edu/ml/datasets/Glass+Identification

Trochę danych o atrybutach:

- 1. Id number: 1 to 214
  2. RI: refractive index
- 3. Na: Sodium (unit measurement: weight percent in corresponding oxide, as are attributes 4-10)
- 4. Mg: Magnesium
- 5. Al: Aluminum
- 6. Si: Silicon
- 7. K: Potassium
- 8. Ca: Calcium
- 9. Ba: Barium
  - A. Fe: Iron
  - B. Type of glass: (class attribute)
  - 1 building\_windows\_float\_processed
  - 2 building\_windows\_non\_float\_processed
  - 3 vehicle windows float processed
  - 4 vehicle\_windows\_non\_float\_processed (none in this database)
  - 5 containers
  - 6 tableware
  - 7 headlamps

# Przydatne importy:

```
In [ ]:
         import pandas as pd
         import numpy as np
         import seaborn as sns
         import matplotlib.pyplot as plt
         plt.style.use('default')
         from sklearn.model selection import train test split
         from sklearn.metrics import accuracy score, confusion matrix, classification report
         from sklearn.preprocessing import StandardScaler, Normalizer, MinMaxScaler
         from sklearn.naive_bayes import GaussianNB
         from sklearn.tree import DecisionTreeClassifier
         from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score,
         from sklearn.model_selection import GridSearchCV
         from sklearn.model_selection import cross_validate
         import warnings
         warnings.filterwarnings('ignore')
```

# Eksploracja danych:

Wczytanie danych

```
In [ ]: data = pd.read_csv('glass.data', names=['Id', 'RI', 'Na', 'Mg', 'Al', 'Si', 'K', 'Ca
```

```
data.shape
         (214, 11)
Out[]:
In [ ]:
          data.drop('Id', axis=1, inplace=True)
          data.head()
Out[]:
                                        Si
                 RI
                           Mg
                                  Αl
                                              Κ
                                                  Ca Ba
                                                           Fe class
                       Na
         0 1.52101 13.64 4.49 1.10 71.78 0.06 8.75
                                                      0.0
                                                           0.0
                                                                  1
         1 1.51761 13.89 3.60
                               1.36 72.73 0.48
                                                7.83
                                                      0.0
                                                           0.0
                                                                  1
         2 1.51618 13.53 3.55
                               1.54
                                     72.99
                                           0.39
                                                7.78
                                                      0.0
                                                           0.0
                                                                  1
           1.51766 13.21 3.69
                               1.29
                                    72.61
                                                 8.22
                                           0.57
                                                      0.0
                                                           0.0
                                                                  1
           1.51742 13.27 3.62 1.24 73.08 0.55 8.07 0.0
                                                          0.0
                                                                  1
        Sprawdzenie, czy są braki danych
In [ ]:
          pd.isnull(data).sum()
                   0
Out[ ]:
         Na
                   0
                   0
         Mg
                   0
         Αl
         Si
                   0
         Κ
                   0
         Ca
                   0
         Ва
                   0
         Fe
                   0
         class
                   0
         dtype: int64
         Sprawdzenie typów danych
In [ ]:
          data.dtypes
                   float64
         RΙ
Out[]:
                   float64
         Na
         Mg
                   float64
         Al
                   float64
                   float64
         Si
         Κ
                   float64
         Ca
                   float64
                   float64
         Ba
                   float64
         Fe
                      int64
         class
         dtype: object
        Wypisanie podstawowych statystyk o danych
In [ ]:
          data.describe()
Out[]:
                        RI
                                                          Αl
                                                                     Si
                                                                                 Κ
                                                                                            Ca
                                                                                                       E
                                  Na
                                             Mg
                           214.000000 214.000000 214.000000 214.000000 214.000000 214.000000 214.000000
         count 214.000000
         mean
                  1.518365
                             13.407850
                                         2.684533
                                                    1.444907
                                                               72.650935
                                                                           0.497056
                                                                                      8.956963
                                                                                                  0.17504
```

std

0.003037

0.816604

1.442408

0.499270

0.774546

0.652192

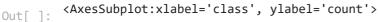
1.423153

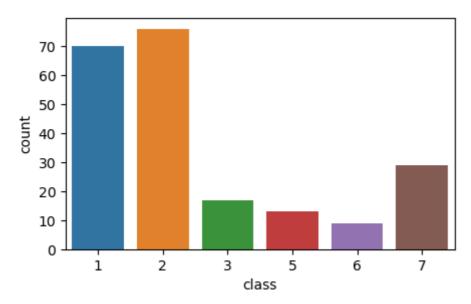
0.49721

	RI	Na	Mg	Al	Si	K	Ca	E
min	1.511150	10.730000	0.000000	0.290000	69.810000	0.000000	5.430000	0.00000
25%	1.516522	12.907500	2.115000	1.190000	72.280000	0.122500	8.240000	0.00000
50%	1.517680	13.300000	3.480000	1.360000	72.790000	0.555000	8.600000	0.00000
75%	1.519157	13.825000	3.600000	1.630000	73.087500	0.610000	9.172500	0.00000
max	1.533930	17.380000	4.490000	3.500000	75.410000	6.210000	16.190000	3.15000

Liczności poszczególnych klas

```
In [ ]:
         data['class'].value_counts()
              76
Out[]:
              70
              29
         3
              17
              13
         6
         Name: class, dtype: int64
        Wizualizacja licznosci poszczególnych klas
In [ ]:
          plt.figure(figsize=[5,3])
         sns.countplot(data["class"])
```



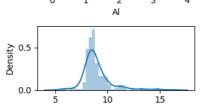


Wystepują znaczne różnice w licznościach klas.

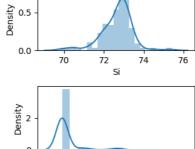
Wizualizacja rozkładu poszczególnych zmiennych w ramach zbioru danych. Dla każdej zmiennej, na osi poziomej przedstawiony jest zakres wartości, a na osi pionowej gęstość prawdopodobieństwa.

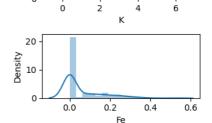
```
In [ ]:
         plt.figure(figsize=[10,5])
         for i in range(0, 9):
             plt.subplot(3, 3, i + 1)
```

```
sns.distplot(data.iloc[:, i])
       plt.tight_layout()
Density
100
                                        0.50
0.25
                                                                                  Density
                                                                                    0.5
                                                                                    0.0
     0
                                           0.00
        1.51
                            1.53
                                                       12
                                                                     16
                                                                            18
                  1.52
                                                10
                                                              14
```



0

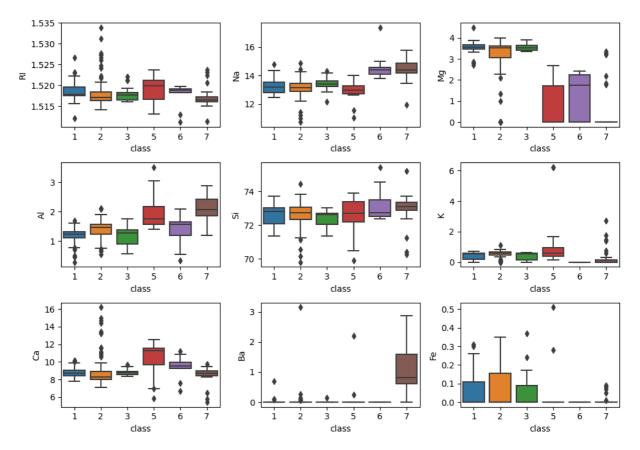




Density 2

Wizualizacja pokazująca różnice w rozkładach wartości numerycznych między różnymi klasami w zbiorze danych. Na osi pionowej przedstawione są wartości numeryczne danej cechy, a na osi poziomej przedstawione są wystepujace w zbiorze klasy. Dla każdej cechy, pudełko wykresu przedstawia interkwartylne zakresy wartości, linia wewnątrz pudełka oznacza medianę, a wąsy przedstawiają rozstęp wartości (różnica między największą a najmniejszą wartością w zbiorze danych). Dodatkowo, punkty lub krzyże mogą reprezentować wartości odstające.

```
In [ ]:
    plt.figure(figsize=[10, 7])
    numeric_features = data.select_dtypes(include=['float64', 'int64']).drop('class', ax
    num_cols = len(numeric_features)
    for i in range(num_cols):
        plt.subplot(3, 3, i + 1)
        sns.boxplot(x='class', y=numeric_features[i], data=data)
    plt.tight_layout()
    plt.show()
```



Wykres ten pokazał, że wartości niektórych cech są bardzo podobne dla różnych klas (np. RI, Si), ale występują też cechy, dla których na przykład wartości dla jednej/kilku klasy są znacznie wyróżniające się na tle pozostałych (np. Mg, Ba) - takie cechy mogą być przydatne przy klasyfikacji.

# Przygotowanie danych:

```
In [ ]: X=data.drop("class", axis = 1)
    y=data["class"]
```

Poszukiwanie dobrego staosunku podziału zbioru na zbiór treningowy i testowy.

```
test_sizes = [.1, .15, .2, .25, .3, .35, .4, .45, .5, .55, .6, .65, .7]
results = pd.DataFrame(columns=['test_size', 'accuracy GNB', 'accuracy DT'])

for test_size in test_sizes:
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=test_size, r
    gnb = GaussianNB()
    gnb.fit(X_train, y_train)
    y_pred_gnb = gnb.predict(X_test)
    dt = DecisionTreeClassifier()
    dt.fit(X_train, y_train)
    y_pred_dt = dt.predict(X_test)
    results = results.append({'test_size': test_size, 'accuracy GNB': accuracy_score}
    results
```

Out[ ]:		test_size	accuracy GNB	accuracy DT
	0	0.10	0.681818	0.545455
	1	0.15	0.575758	0.545455
	2	0.20	0.441860	0.720930

	test_size	accuracy GNB	accuracy DT
3	0.25	0.407407	0.722222
4	0.30	0.430769	0.661538
5	0.35	0.413333	0.640000
6	0.40	0.500000	0.639535
7	0.45	0.556701	0.690722
8	0.50	0.551402	0.710280
9	0.55	0.550847	0.677966
10	0.60	0.573643	0.666667
11	0.65	0.521429	0.614286
12	0.70	0.540000	0.653333

Najlepszy rezultat zmienia się za każdym razem gdy na nowo losujemy kolejność wierszy z danymi. Dlatego też, aby uzyskać jak najbardziej wiarygodne wyniki, należy powtórzyć eksperyment kilkukrotnie i uśrednić wyniki.

# Out[]: accuracy GNB accuracy DT

test_size						
0.10	0.681818	0.613636				
0.15	0.575758	0.642424				
0.20	0.441860	0.704651				
0.25	0.407407	0.712963				
0.30	0.430769	0.675385				
0.35	0.413333	0.673333				
0.40	0.500000	0.641860				
0.45	0.556701	0.680412				
0.50	0.551402	0.694393				
0.55	0.550847	0.659322				
0.60	0.573643	0.643411				

#### accuracy GNB accuracy DT

test_size		
0.65	0.521429	0.602857
0.70	0.540000	0.642000

Eksperyment nie jest jednoznaczny, jeden z najlepszych wyników został osiągany dla podziału 80/20 (zbiór treningowy/testowy). Ten podział zostanie wykorzystany w następnych eksperymentach.

Standaryzacja danych - jest to przekształcenia wartości cech w taki sposób, aby miały średnią wartość równą 0 i odchylenie standardowe równa 1. Polega ona na odjęciu średniej wartości cechy od każdej obserwacji, a następnie podzieleniu jej przez odchylenie standardowe. Dzięki temu standaryzacja danych przekształca rozkład cech w taki sposób, że mają one zbliżone skale i jednostki, co ułatwia porównywanie i analizę danych.

```
scaler = StandardScaler()
X_train_standardized = scaler.fit_transform(X_train)
X_test_standardized = scaler.transform(X_test)
```

Normalizacja danych - skalowania wartości cech tak, aby każda obserwacja miała długość równą 1. Dzięki temu, wartości cech są przekształcane w sposób, który zachowuje proporcje między nimi, niezależnie od ich skal. Jest to przydatne, gdy chcemy porównywać względne proporcje między różnymi cechami lub obserwacjami, niezależnie od ich oryginalnych wartości.

```
In [ ]:
    normalizer = Normalizer()
    X_train_normalized = normalizer.fit_transform(X_train)
    X_test_normalized = normalizer.transform(X_test)
```

Funkcja przydatna przy pokazywaniu wyników klasyfikacji.

```
def test_classifier(cls, X_train, y_train, X_test, y_test):
    cls.fit(X_train, y_train)
    y_pred = cls.predict(X_test)

accuracy_score_test = accuracy_score(y_test, y_pred)
    precision_score_test = precision_score(y_test, y_pred, average='weighted')
    recall_score_test = recall_score(y_test, y_pred, average='weighted')
    fl_score_test = fl_score(y_test, y_pred, average='weighted')

results = pd.DataFrame(columns=['Accuracy', 'Precision', 'Recall', 'F1 Score'])
    results.loc[cls.__class__.__name__] = [accuracy_score_test, precision_score_test
    print(results, "\n")

# Confusion matrix
    confusion_matrix_test = confusion_matrix(y_test, y_pred)
    print("Confusion matrix: \n", confusion_matrix(y_test, y_pred), "\n")
```

```
# Classification report
print("Classification report: \n", classification_report(y_test, y_pred), "\n")
return results, confusion_matrix_test
```

# Porównanie metod przetwarzających dane:

```
In [ ]:
       print("Naive Bayes Classifier:")
       print("-----\n")
       results_gnb_proc_df = pd.DataFrame(columns=['Experiment', 'Accuracy', 'Precision', '
       print("Pure data:")
       print("-----\n")
       results_gnb_proc, _ = test_classifier(GaussianNB(), X_train, y_train, X_test, y_test
       results_gnb_proc['Experiment'] = 'Pure data'
       results_gnb_proc_df = results_gnb_proc_df.append(results_gnb_proc, ignore_index=True
       print("With Standardization:")
       print("-----\n")
       results_gnb_proc, _ = test_classifier(GaussianNB(), X_train_standardized, y_train, X
       results_gnb_proc['Experiment'] = 'Standardization'
       results_gnb_proc_df = results_gnb_proc_df.append(results_gnb_proc, ignore_index=True
       print("With Normalization:")
       print("-----\n")
       results_gnb_proc, _ = test_classifier(GaussianNB(), X_train_normalized, y_train, X_t
       results_gnb_proc['Experiment'] = 'Normalization'
       results_gnb_proc_df = results_gnb_proc_df.append(results_gnb_proc, ignore_index=True
       print("\n")
      Naive Bayes Classifier:
      Pure data:
                Accuracy Precision Recall F1 Score
      GaussianNB 0.44186 0.440476 0.44186 0.413577
      Confusion matrix:
       [[10 1 4 0 0 0]
       [832210]
       [202010]
       [030000]
       [000010]
       [000003]]
      Classification report:
                   precision recall f1-score support
                     0.50
                             0.67
                                     0.57
               1
                                                15
               2
                     0.43
                             0.19
                                      0.26
                                                16
                     0.25
               3
                            0.40
                                     0.31
                                                5
                                                3
               5
                     0.00
                            0.00
                                     0.00
                     0.33 1.00
1.00 1.00
                                     0.50
                                     1.00
                                                3
```

0.44

0.44

0.41

0.42 0.54

0.44

0.44

accuracy

weighted avg

macro avg

43

43

43

-----

Accuracy Precision Recall F1 Score GaussianNB 0.44186 0.440476 0.44186 0.413577

# Confusion matrix:

[[10 1 4 0 0 0] [8 3 2 2 1 0] [2 0 2 0 1 0] [0 3 0 0 0 0] [0 0 0 0 0 3]]

#### Classification report:

	precision	recall	f1-score	support
1	0.50	0.67	0.57	15
2	0.43	0.19	0.26	16
3	0.25	0.40	0.31	5
5	0.00	0.00	0.00	3
6	0.33	1.00	0.50	1
7	1.00	1.00	1.00	3
accuracy			0.44	43
macro avg	0.42	0.54	0.44	43
weighted avg	0.44	0.44	0.41	43

#### With Normalization:

\_\_\_\_\_

Accuracy Precision Recall F1 Score GaussianNB 0.44186 0.407145 0.44186 0.39329

# Confusion matrix:

[[11 1 3 0 0 0] [10 2 1 2 1 0] [2 0 2 0 1 0] [0 3 0 0 0 0] [0 0 0 0 1 0] [0 0 0 0 0 3]]

	precision	recall	f1-score	support
1	0.48	0.73	0.58	15
2	0.33	0.12	0.18	16
3	0.33	0.40	0.36	5
5	0.00	0.00	0.00	3
6	0.33	1.00	0.50	1
7	1.00	1.00	1.00	3
accuracy			0.44	43
macro avg	0.41	0.54	0.44	43
weighted avg	0.41	0.44	0.39	43

```
In [ ]: results_gnb_proc_df.sort_values(by=['Accuracy', 'Precision', 'F1 Score'], ascending=
```

```
        Out[]:
        Experiment
        Accuracy
        Precision
        Recall
        F1 Score

        0
        Pure data
        0.44186
        0.440476
        0.44186
        0.413577

        1
        Standardization
        0.44186
        0.440476
        0.44186
        0.413577

        2
        Normalization
        0.44186
        0.407145
        0.44186
        0.393290
```

Procesowanie danych nie pomogło w uzyskaniu lepszych wyników klasyfikacji. Wyniki są takie same, jak w przypadku, gdy nie stosowano żadnego przetwarzania danych. W przypadku normalizacji danych, wyniki są nieco gorsze (precyzja). Można również zauważyć różnice w macierzy pomyłek (zwłaszcza dla klasy 2, normalizacja ma inne trafienia) Ogólnie wyniki klasyfikatora Bayesa nie są zbyt dobre (mniej niż 50% trafień). Na plus idealna dokładność dla klasy 6 i 7, za to fatalna dla klasy 2 i 5.

```
In [ ]:
       print("Decision Tree Classifier:")
       print("-----\n")
       results_dt_proc_df = pd.DataFrame(columns=['Experiment', 'Accuracy', 'Precision', 'R
       print("Pure data:")
       print("-----\n")
       results dt_proc, _ = test_classifier(DecisionTreeClassifier(), X_train, y_train, X_t
       results_dt_proc['Experiment'] = 'Pure data'
       results_dt_proc_df = results_dt_proc_df.append(results_dt_proc, ignore_index=True)
       print("With Standardization:")
       print("-----\n")
       results_dt_proc, _ = test_classifier(DecisionTreeClassifier(), X_train_standardized,
       results_dt_proc['Experiment'] = 'Standardization'
       results_dt_proc_df = results_dt_proc_df.append(results_dt_proc, ignore_index=True)
       print("With Normalization:")
       print("-----\n")
       results_dt_proc, _ = test_classifier(DecisionTreeClassifier(), X_train_normalized, y
       results dt proc['Experiment'] = 'Normalization'
       results_dt_proc_df = results_dt_proc_df.append(results_dt_proc, ignore_index=True)
       print("\n")
       Decision Tree Classifier:
       Pure data:
                           Accuracy Precision Recall F1 Score
       DecisionTreeClassifier 0.674419 0.689746 0.674419 0.670199
```

Confusion matrix:

[[8 4 2 0 1 0] [2 12 0 1 1 0] [1 2 2 0 0 0] [0 0 0 3 0 0] [0 0 0 0 1 0] [0 0 0 0 3]]

	precision	recall	f1-score	support
1	0.73	0.53	0.62	15
2	0.67	0.75	0.71	16
3	0.50	0.40	0.44	5
5	0.75	1.00	0.86	3
6	0.33	1.00	0.50	1
7	1.00	1.00	1.00	3
accuracy			0.67	43
macro avg	0.66	0.78	0.69	43
weighted avg	0.69	0.67	0.67	43

# With Standardization:

-----

Accuracy Precision Recall F1 Score DecisionTreeClassifier 0.697674 0.648837 0.697674 0.662237

# Confusion matrix:

[[10 3 1 0 0 1] [113 0 1 1 0] [1 4 0 0 0 0] [0 0 0 3 0 0] [0 0 0 0 1 0] [0 0 0 0 0 3]]

# Classification report:

	precision	recall	f1-score	support
1	0.83	0.67	0.74	15
2	0.65	0.81	0.72	16
3	0.00	0.00	0.00	5
5	0.75	1.00	0.86	3
6	0.50	1.00	0.67	1
7	0.75	1.00	0.86	3
accuracy			0.70	43
macro avg	0.58	0.75	0.64	43
weighted avg	0.65	0.70	0.66	43

#### With Normalization:

-----

Accuracy Precision Recall F1 Score
DecisionTreeClassifier 0.72093 0.723064 0.72093 0.714402

# Confusion matrix:

[[10 4 1 0 0 0] [2 12 0 1 1 0] [2 1 2 0 0 0] [0 0 0 3 0 0] [0 0 0 0 1 0] [0 0 0 0 0 3]]

	precision	recall	f1-score	support
1	0.71	0.67	0.69	15
2	0.71	0.75	0.73	16
3	0.67	0.40	0.50	5
5	0.75	1.00	0.86	3

6 7	0.50 1.00	1.00 1.00	0.67 1.00	1 3
accuracy			0.72	43
macro avg	0.72	0.80	0.74	43
weighted avg	0.72	0.72	0.71	43

```
In [ ]:
         results_dt_proc_df.sort_values(by=['Accuracy', 'Precision', 'F1 Score'], ascending=F
Out[]:
              Experiment Accuracy Precision
                                               Recall F1 Score
             Normalization 0.720930 0.723064 0.720930 0.714402
         1 Standardization 0.697674 0.648837 0.697674 0.662237
                Pure data 0.674419 0.689746 0.674419 0.670199
```

Wyniki dla klasyfikatora drzewa decyzyjnego są znacznie lepsze niż dla klasyfikatora Bayesa. W wypadku tego klasyfikatora procesowanie danych przyniosło poprawę wyników. Wystepują różnice w macierzy pomyłek między poszczególnymi metodami przetwarzania danych. Zmiana klasyfikatora (a zwłaszcza z użyciem normalizacji) znacznie poprawiła wyniki dla klasy 2 i 5, jednak klasa 3 wciąż stanowi problem.

# Porównanie skuteczności hiperparametrów:

```
In [ ]:
         param_gnb = {'var_smoothing': np.logspace(0, -10, num=100)}
         grid search_gnb = GridSearchCV(GaussianNB(), param_gnb, scoring='accuracy', cv=5)
         print("Best parameters for Gaussian Naive Bayes: ", grid_search_gnb.fit(X_train, y_t
```

Best parameters for Gaussian Naive Bayes: {'var\_smoothing': 0.012045035402587823}

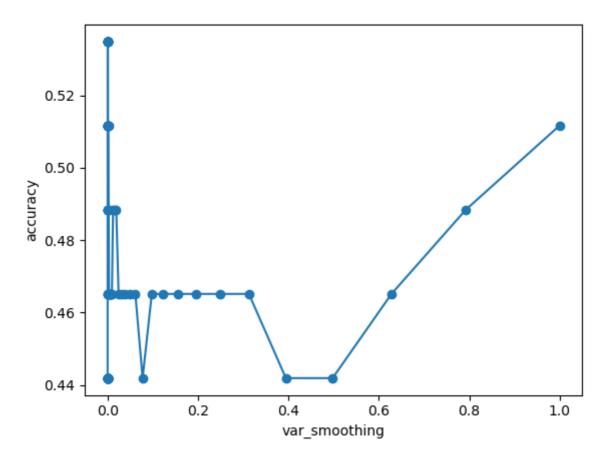
Wizualizacja pokazująca dokładność klasyfikatora Bayesa w zależności od hiperparametru 'var\_smoothing' (umożliwia dodanie małej wartości do wariancji wszystkich cech, która wygładza wariancje i pomaga uniknać problemu zerowych lub niskich wariancji, które skutkują problemami w wyliczaniu prawdopodobieństw).

```
In [ ]:
         acc scores = []
         var_smoothing_values = param_gnb['var_smoothing']
         for var smoothing in var smoothing values:
             clf = GaussianNB(var smoothing=var smoothing)
             clf.fit(X_train, y_train)
             y pred = clf.predict(X test)
             acc = accuracy_score(y_test, y_pred)
             acc_scores.append(acc)
         best_var_smoothing = var_smoothing_values[np.argmax(acc_scores)]
         print("Best var_smoothing value: ", best_var_smoothing, "\n")
         plt.plot(var smoothing values, acc scores, marker='o')
         plt.xlabel('var_smoothing')
```

```
plt.ylabel('accuracy')
plt.show()
```

Best var smoothing value: 0.0007390722033525783

In [ ]:

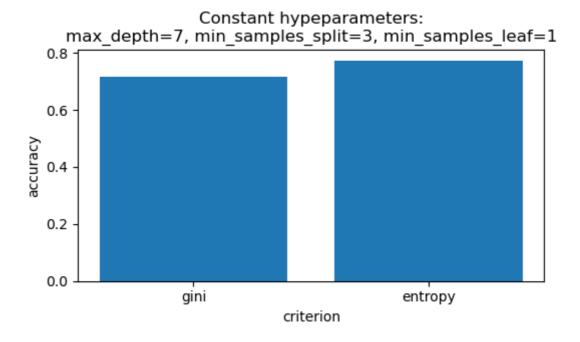


```
param_dt_grid = {
             'criterion': ['gini', 'entropy'],
             'max_depth': range(1, 10),
             'min_samples_split': range(2, 10),
             'min_samples_leaf': range(1, 5),
         }
         grid_search_dt = GridSearchCV(estimator = DecisionTreeClassifier(), param_grid = par
         grid_search_dt.fit(X_train, y_train)
         print("Best parameters: ", grid_search_dt.best_params_)
        Best parameters: {'criterion': 'gini', 'max depth': 7, 'min samples leaf': 1, 'min
        samples split': 3}
In [ ]:
         best_params = grid_search_dt.best_params_
         criterion = best_params['criterion']
         max_depth = best_params['max_depth']
         min samples split = best params['min samples split']
         min_samples_leaf = best_params['min_samples_leaf']
```

Wizuazlizacja pokazująca dokładność klasyfikatora drzewa decyzyjnego w zależności od hiperparametru 'criterion' (kryterium podziału w węźle drzewa).

```
In [ ]:
         criterion_values = ['gini', 'entropy']
         acc_scores_criterion = []
         for criterion_val in criterion_values:
             acc scores = []
             for in range(100):
```

Best criterion value: entropy

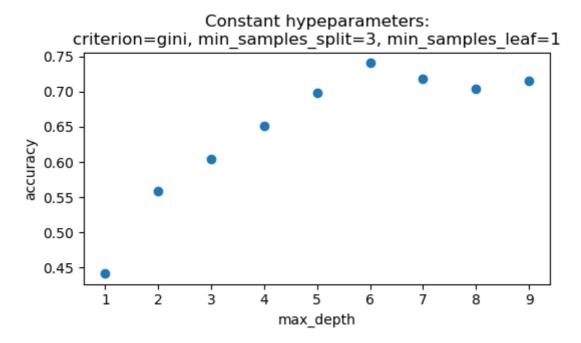


Wizualizacja pokazująca dokładność klasyfikatora drzewa decyzyjnego w zależności od hiperparametru 'max\_depth' (maksymalna głębokość drzewa).

```
In [ ]:
         max_depth_values = range(1, 10)
         acc scores max depth = []
         for max_depth_val in max_depth_values:
             acc_scores = []
             for _ in range(100):
                 clf = DecisionTreeClassifier(criterion=criterion, max_depth=max_depth_val,
                                           min samples split=min samples split, min samples le
                 clf.fit(X_train, y_train)
                 y pred = clf.predict(X test)
                 acc = accuracy_score(y_test, y_pred)
                 acc_scores.append(acc)
             acc_scores_max_depth.append(np.mean(acc_scores))
         best_max_depth = max_depth_values[np.argmax(acc_scores_max_depth)]
         print("Best max_depth value: ", best_max_depth, "\n")
         plt.figure(figsize=(6, 3))
         plt.scatter(max_depth_values, acc_scores_max_depth, marker='o')
```

```
plt.xlabel('max_depth')
plt.ylabel('accuracy')
plt.title('Constant hypeparameters:\ncriterion={}, min_samples_split={}, min_samples
plt.show()
```

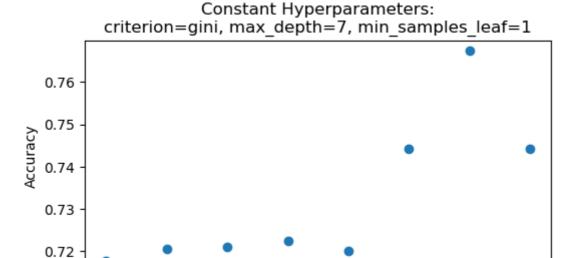
Best max\_depth value: 6



Wizualizacja pokazująca dokładność klasyfikatora drzewa decyzyjnego w zależności od hiperparametru 'min\_samples\_split' (minimalna liczba próbek wymagana do podziału węzła).

```
In [ ]:
         acc_scores_min_samples_split = []
         min samples split values = range(2, 10)
         for min_samples_split_val in min_samples_split_values:
             acc_scores = []
             for _ in range(100):
                 clf = DecisionTreeClassifier(criterion=criterion, max_depth=max_depth,
                                              min_samples_split=min_samples_split_val, min_sa
                 clf.fit(X_train, y_train)
                 y_pred = clf.predict(X_test)
                 acc = accuracy_score(y_test, y_pred)
                 acc scores.append(acc)
             acc scores min samples split.append(np.mean(acc scores))
         best_min_samples_split = min_samples_split_values[np.argmax(acc_scores_min_samples_s
         print("Best min_samples_split value: ", best_min_samples_split, "\n")
         plt.figure(figsize=(6, 3))
         plt.scatter(min_samples_split_values, acc_scores_min_samples_split, marker='o')
         plt.xlabel('min_samples_split')
         plt.ylabel('Accuracy')
         plt.title('Constant Hyperparameters:\ncriterion={}, max_depth={}, min_samples_leaf={
         plt.show()
```

Best min\_samples\_split value: 8



Wizualizacja pokazująca dokładność klasyfikatora drzewa decyzyjnego w zależności od hiperparametru 'min\_samples\_leaf' (minimalna liczba próbek wymagana do znalezienia liścia).

min\_samples\_split

5

4

7

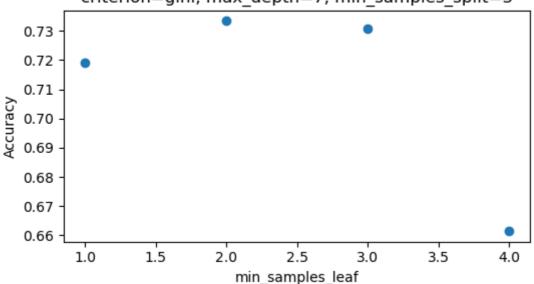
8

9

```
In [ ]:
         acc_scores_min_samples_leaf = []
         min_samples_leaf_values = range(1, 5)
         for min_samples_leaf_val in min_samples_leaf_values:
             acc_scores = []
             for _ in range(100):
                 clf = DecisionTreeClassifier(criterion=criterion, max_depth=max_depth,
                                               min_samples_split=min_samples_split, min_sample
                 clf.fit(X_train, y_train)
                 y_pred = clf.predict(X_test)
                 acc = accuracy_score(y_test, y_pred)
                 acc_scores.append(acc)
             acc_scores_min_samples_leaf.append(np.mean(acc_scores))
         best_min_samples_leaf = min_samples_leaf_values[np.argmax(acc_scores_min_samples_lea
         print("Best min_samples_leaf value: ", best_min_samples_leaf, "\n")
         plt.figure(figsize=(6, 3))
         plt.scatter(min_samples_leaf_values, acc_scores_min_samples_leaf, marker='o')
         plt.xlabel('min_samples_leaf')
         plt.ylabel('Accuracy')
         plt.title('Constant Hyperparameters:\ncriterion={}, max_depth={}, min_samples_split=
         plt.show()
```

Best min\_samples\_leaf value: 2

# Constant Hyperparameters: criterion=gini, max depth=7, min samples split=3



# Porównanie skuteczności klasyfikatorów przy kilku zestawach parametrów:

```
In [ ]:
         params_gnb = [{'var_smoothing': grid_search_gnb.best_params_['var_smoothing']},
                       {'var_smoothing': best_var_smoothing},
                       {'var_smoothing': 1e-9},] # default value
         # delete duplicates
         params_gnb = [dict(t) for t in {tuple(d.items()) for d in params_gnb}]
         params_gnb
        [{'var_smoothing': 0.012045035402587823},
Out[]:
         {'var_smoothing': 1e-09},
         {'var_smoothing': 0.0007390722033525783}]
In [ ]:
         params_dt = [{'criterion': grid_search_dt.best_params_['criterion'],
                          'max_depth': grid_search_dt.best_params_['max_depth'],
                          'min_samples_split': grid_search_dt.best_params_['min_samples_split'
                          'min_samples_leaf': grid_search_dt.best_params_['min_samples_leaf']}
                          {'criterion': best_criterion,
                           'max_depth': grid_search_dt.best_params_['max_depth'],
                          'min samples split': grid search dt.best params ['min samples split'
                          'min_samples_leaf': grid_search_dt.best_params_['min_samples_leaf']}
                          {'criterion': grid_search_dt.best_params_['criterion'],
                          'max_depth': best_max_depth,
                          'min_samples_split': grid_search_dt.best_params_['min_samples_split'
                          'min_samples_leaf': grid_search_dt.best_params_['min_samples_leaf']}
                          {'criterion': grid search dt.best params ['criterion'],
                          'max_depth': grid_search_dt.best_params_['max_depth'],
                          'min_samples_split': best_min_samples_split,
                          'min_samples_leaf': grid_search_dt.best_params_['min_samples_leaf']}
                          {'criterion': grid_search_dt.best_params_['criterion'],
                          'max_depth': grid_search_dt.best_params_['max_depth'],
                          'min_samples_split': grid_search_dt.best_params_['min_samples_split'
                          'min_samples_leaf': best_min_samples_leaf},
                          {'criterion': best_criterion,
                           'max_depth': best_max_depth,
                           'min_samples_split': best_min_samples_split,
                           'min_samples_leaf': best_min_samples_leaf},
                          {'criterion': 'gini',
                           'max_depth': None,
                           'min_samples_split': 2,
```

```
'min_samples_leaf': 1}] # default values
         # delete duplicates
         params dt = [dict(t) for t in {tuple(d.items()) for d in params dt}]
         params dt
Out[]: [{'criterion': 'entropy',
           'max_depth': 7,
          'min_samples_split': 3,
          'min_samples_leaf': 1},
         {'criterion': 'gini',
          'max_depth': None,
          'min_samples_split': 2,
          'min_samples_leaf': 1},
         {'criterion': 'gini',
          'max_depth': 7,
          'min_samples_split': 3,
          'min_samples_leaf': 1},
         {'criterion': 'gini',
          'max_depth': 7,
          'min_samples_split': 8,
          'min_samples_leaf': 1},
         {'criterion': 'entropy',
          'max_depth': 6,
          'min_samples_split': 8,
          'min_samples_leaf': 2},
         {'criterion': 'gini',
          'max_depth': 7,
          'min_samples_split': 3,
          'min_samples_leaf': 2},
         {'criterion': 'gini',
          'max_depth': 6,
          'min_samples_split': 3,
          'min_samples_leaf': 1}]
In [ ]:
         # Gaussian Naive Bayes Classifier
         print("Gaussian Naive Bayes Classifier:")
         print("-----\n")
         results_gnb_df = pd.DataFrame(columns=['var_smoothing', 'Accuracy', 'Precision', 'Re
         for params in params_gnb:
             print("Parameter set:", params)
             print("-----
             clf = GaussianNB(**params)
             results_gnb, _ = test_classifier(clf, X_train, y_train, X_test, y_test)
             results_gnb['var_smoothing'] = params['var_smoothing']
             results gnb df = results gnb df.append(results gnb, ignore index=True)
             print("\n")
        Gaussian Naive Bayes Classifier:
        ______
        Parameter set: {'var_smoothing': 0.012045035402587823}
                    Accuracy Precision Recall F1 Score
        GaussianNB 0.488372 0.435846 0.488372 0.408739
        Confusion matrix:
         [[14 0 1 0 0 0]
         [10 3 0 2 1 0]
         [5 0 0 0 0 0]
```

[	0	3	0	0	0	0]
[	0	0	0	0	1	0]
[	0	0	0	0	0	3]]

# Classification report:

	precision	recall	f1-score	support
1	0.48	0.93	0.64	15
2	0.50	0.19	0.27	16
3	0.00	0.00	0.00	5
5	0.00	0.00	0.00	3
6	0.50	1.00	0.67	1
7	1.00	1.00	1.00	3
accuracy			0.49	43
macro avg	0.41	0.52	0.43	43
weighted avg	0.44	0.49	0.41	43

Parameter set: {'var\_smoothing': 1e-09}

\_\_\_\_\_

Accuracy Precision Recall F1 Score GaussianNB 0.44186 0.440476 0.44186 0.413577

#### Confusion matrix:

[[10 1 4 0 0 0] [832210] [202010] [030000] [000010] [000003]]

# Classification report:

	precision	recall	f1-score	support
1	0.50	0.67	0.57	15
2	0.43	0.19	0.26	16
3	0.25	0.40	0.31	5
5	0.00	0.00	0.00	3
6	0.33	1.00	0.50	1
7	1.00	1.00	1.00	3
accuracy			0.44	43
macro avg	0.42	0.54	0.44	43
weighted avg	0.44	0.44	0.41	43

Parameter set: {'var\_smoothing': 0.0007390722033525783}

Accuracy Precision Recall F1 Score GaussianNB 0.534884 0.535153 0.534884 0.498368

\_\_\_\_\_

Confusion matrix: [[13 1 0 0 1 0] [841120] [ 2 0 2 0 1 0] [030000] [000010]

#### Classification report: precision recall f1-score support 0.57 0.87 1 0.68 15 2 0.50 0.25 0.33 16 3 0.67 0.40 0.50 5 5 0.00 0.00 0.00 3 0.20 0.33 1 6 1.00 1.00 1.00 1.00 3 0.53 43 accuracy macro avg 0.49 0.59 0.48 43 weighted avg 0.54 0.53 0.50 43

```
In [ ]: results_gnb_df.sort_values(by=['Accuracy', 'Precision'], ascending=False)
```

Out[ ]:	var_smoothing		var_smoothing Accuracy Precision		Recall	F1 Score	
	2	7.390722e-04	0.534884	0.535153	0.534884	0.498368	
	0	1.204504e-02	0.488372	0.435846	0.488372	0.408739	
	1	1.000000e-09	0.441860	0.440476	0.441860	0.413577	

Najbardziej dokładny jest klasyfikator Bayesa dla hiperparametru 'var\_smoothing' równego 7.390722e-04 (czyli znaleziony przez sprawdzanie wszystkich wartości ze 100 próbek wybranych przez np.logspace(0, -10, num=100)). Najgorzej wypada domyślna wartość tego hipermarametru (1e-09). Problemy wystąpiły dla klasy 5, gdzie klasyfikator nie przewidział żadnej obserwacji tej klasy. Wygrywająca wartość hiperparametru zyskała pzrewagę przez lepszą dokładność dla klasy 1 niż wartość wybrana jako najlepsza przez grid search oraz dla klasy 3 w stosunku do wartości domyślnej.

```
In [ ]:
        # Decision Tree Classifier
        print("Decision Tree Classifier:")
        print("-----\n")
        results_dt_df = pd.DataFrame(columns=['criterion', 'max_depth', 'min_samples_split',
        for params in params_dt:
            print("Parameter set:", params)
            print("-----
            clf = DecisionTreeClassifier(**params)
            results_dt, _ = test_classifier(clf, X_train, y_train, X_test, y_test)
            results_dt['criterion'] = params['criterion']
            results_dt['max_depth'] = params['max_depth']
            results_dt['min_samples_split'] = params['min_samples_split']
            results_dt['min_samples_leaf'] = params['min_samples_leaf']
            results_dt_df = results_dt_df.append(results_dt, ignore_index=True)
            print("\n")
```

Decision Tree Classifier:

```
Parameter set: {'criterion': 'entropy', 'max_depth': 7, 'min_samples_split': 3, 'min_samples_leaf': 1}
```

\_\_\_\_\_\_

Accuracy Precision Recall F1 Score DecisionTreeClassifier 0.767442 0.810674 0.767442 0.763201

#### Confusion matrix:

[[11 4 0 0 0 0] [1 14 0 0 1 0] [1 2 2 0 0 0] [0 1 0 2 0 0] [0 0 0 0 1 0] [0 0 0 0 0 3]]

# Classification report:

	precision	recall	f1-score	support
1	0.85	0.73	0.79	15
2	0.67	0.88	0.76	16
3	1.00	0.40	0.57	5
5	1.00	0.67	0.80	3
6	0.50	1.00	0.67	1
7	1.00	1.00	1.00	3
accuracy			0.77	43
macro avg	0.84	0.78	0.76	43
weighted avg	0.81	0.77	0.76	43

Parameter set: {'criterion': 'gini', 'max\_depth': None, 'min\_samples\_split': 2, 'min\_samples\_leaf': 1}

-----

Accuracy Precision Recall F1 Score DecisionTreeClassifier 0.697674 0.662403 0.697674 0.668328

#### Confusion matrix:

[[10 3 1 0 1 0] [113 0 1 1 0] [1 4 0 0 0 0] [0 0 0 3 0 0] [0 0 0 0 1 0] [0 0 0 0 0 3]]

		precision	recall	f1-score	support
	1	0.83	0.67	0.74	15
	2	0.65	0.81	0.72	16
	3	0.00	0.00	0.00	5
	5	0.75	1.00	0.86	3
	6	0.33	1.00	0.50	1
	7	1.00	1.00	1.00	3
accui	racy			0.70	43
macro	avg	0.59	0.75	0.64	43
weighted	avg	0.66	0.70	0.67	43

```
Parameter set: {'criterion': 'gini', 'max_depth': 7, 'min_samples_split': 3, 'min_sa
mples_leaf': 1}
```

-----

Accuracy Precision Recall F1 Score DecisionTreeClassifier 0.697674 0.638937 0.697674 0.660981

#### Confusion matrix:

[[11 3 0 0 1 0] [2 12 0 1 1 0] [1 4 0 0 0 0] [0 0 0 3 0 0] [0 0 0 0 1 0] [0 0 0 0 0 3]]

#### Classification report:

	precision	recall	f1-score	support
1	0.79	0.73	0.76	15
2	0.63	0.75	0.69	16
3	0.00	0.00	0.00	5
5	0.75	1.00	0.86	3
6	0.33	1.00	0.50	1
7	1.00	1.00	1.00	3
accuracy			0.70	43
macro avg	0.58	0.75	0.63	43
weighted avg	0.64	0.70	0.66	43

Parameter set: {'criterion': 'gini', 'max\_depth': 7, 'min\_samples\_split': 8, 'min\_sa
mples\_leaf': 1}

-----

Accuracy Precision Recall F1 Score DecisionTreeClassifier 0.767442 0.791724 0.767442 0.7612

#### Confusion matrix:

[[12 3 0 0 0 0] [2 12 0 1 1 0] [1 2 2 0 0 0] [0 0 0 3 0 0] [0 0 0 0 1 0] [0 0 0 0 0 3]]

		precision	recall	f1-score	support
	1	0.80	0.80	0.80	15
	2	0.71	0.75	0.73	16
	3	1.00	0.40	0.57	5
	5	0.75	1.00	0.86	3
	6	0.50	1.00	0.67	1
	7	1.00	1.00	1.00	3
accur	racy			0.77	43
macro	avg	0.79	0.83	0.77	43
weighted	avg	0.79	0.77	0.76	43

```
Parameter set: {'criterion': 'entropy', 'max_depth': 6, 'min_samples_split': 8, 'min_samples_leaf': 2}
```

\_\_\_\_\_\_

Accuracy Precision Recall F1 Score DecisionTreeClassifier 0.744186 0.779623 0.744186 0.725316

#### Confusion matrix:

[[12 3 0 0 0 0] [114 0 0 1 0] [1 3 1 0 0 0] [0 1 0 2 0 0] [0 0 0 1 0 0] [0 0 0 0 3]]

#### Classification report:

	precision	recall	f1-score	support
1	0.86	0.80	0.83	15
2	0.67	0.88	0.76	16
3	1.00	0.20	0.33	5
5	0.67	0.67	0.67	3
6	0.00	0.00	0.00	1
7	1.00	1.00	1.00	3
accuracy			0.74	43
macro avg	0.70	0.59	0.60	43
weighted avg	0.78	0.74	0.73	43

Parameter set: {'criterion': 'gini', 'max\_depth': 7, 'min\_samples\_split': 3, 'min\_sa
mples\_leaf': 2}

-----

Accuracy Precision Recall F1 Score DecisionTreeClassifier 0.744186 0.795884 0.744186 0.730454

#### Confusion matrix:

[[11 3 0 0 1 0] [113 0 1 1 0] [1 3 1 0 0 0] [0 0 0 3 0 0] [0 0 0 0 1 0] [0 0 0 0 3]]

		precision	recall	f1-score	support
	1	0.85	0.73	0.79	15
	2	0.68	0.81	0.74	16
	3	1.00	0.20	0.33	5
	5	0.75	1.00	0.86	3
	6	0.33	1.00	0.50	1
	7	1.00	1.00	1.00	3
accur	racy			0.74	43
macro	avg	0.77	0.79	0.70	43
weighted	avg	0.80	0.74	0.73	43

```
Parameter set: {'criterion': 'gini', 'max_depth': 6, 'min_samples_split': 3, 'min_samples_leaf': 1}

Accuracy Precision Recall F1 Score

DecisionTreeClassifier 0.744186 0.791412 0.744186 0.742451

Confusion matrix:

[[10 4 0 0 1 0]

[ 1 13 0 1 1 0]

[ 1 2 2 0 0 0]

[ 0 0 0 3 0 0]

[ 0 0 0 0 0 3]]
```

Classification report:

CIGSSI, ICGCIO	cpo. c.			
	precision	recall	f1-score	support
4	0.03	0.67	0.74	4.5
1	0.83	0.67	0.74	15
2	0.68	0.81	0.74	16
3	1.00	0.40	0.57	5
5	0.75	1.00	0.86	3
6	0.33	1.00	0.50	1
7	1.00	1.00	1.00	3
accuracy			0.74	43
macro avg	0.77	0.81	0.74	43
weighted avg	0.79	0.74	0.74	43

Out[ ]:		criterion	max_depth	min_samples_split	min_samples_leaf	Accuracy	Precision	Recall	F1 Score
	0	entropy	7	3	1	0.767442	0.810674	0.767442	0.76320
	3	gini	7	8	1	0.767442	0.791724	0.767442	0.761200
	5	gini	7	3	2	0.744186	0.795884	0.744186	0.730454
	6	gini	6	3	1	0.744186	0.791412	0.744186	0.74245
	4	entropy	6	8	2	0.744186	0.779623	0.744186	0.725310
	1	gini	None	2	1	0.697674	0.662403	0.697674	0.668328

3

results\_dt\_df.sort\_values(by=['Accuracy', 'Precision'], ascending=False)

W przypadku klasyfikatora drzewa decyzyjnego najlepszym zestawem parametrów został zestaw określony jako najlepszy przez grid search, ale ze zmienionym hiperparametrem 'critertion' na 'entropy'. Z tą samą dokładnością, ale mniejszą precyzją zakończył eksperyment zestaw parametrów ze zmienionym hiperparametrem 'min\_samples\_split'. Najgorzej wypadają co ciekawe hiperparametry znalezione przez grid search oraz domyślne.

1 0.697674 0.638937 0.697674 0.66098

# Walidacja krzyżowa:

gini

2

```
# Gaussian Naive Bayes Classifier
scoring = ['accuracy', 'precision_weighted', 'recall_weighted', 'f1_weighted']
```

```
results_gnb_df_cv = pd.DataFrame(columns=['var_smoothing'])

for params in params_gnb:
    clf = GaussianNB(**params)
    cv_results = cross_validate(clf, X, y, cv=5, scoring=scoring)

results_gnb = {
        'var_smoothing': params['var_smoothing'],
        'Accuracy': cv_results['test_accuracy'].mean(),
        'Precision': cv_results['test_precision_weighted'].mean(),
        'Recall': cv_results['test_frecall_weighted'].mean(),
        'F1 Score': cv_results['test_f1_weighted'].mean()
}

results_gnb_df_cv = results_gnb_df_cv.append(results_gnb, ignore_index=True)

results_gnb_df_cv.sort_values(by=['Accuracy', 'Precision'], ascending=False)
```

```
        Out[]:
        var_smoothing
        Accuracy
        F1 Score
        Precision
        Recall

        0
        1.204504e-02
        0.471982
        0.389414
        0.390603
        0.471982

        2
        7.390722e-04
        0.448505
        0.396589
        0.411128
        0.448505

        1
        1.000000e-09
        0.345293
        0.320733
        0.369824
        0.345293
```

```
In [ ]:
        # Decision Tree Classifier
         scoring = ['accuracy', 'precision_weighted', 'recall_weighted', 'f1_weighted']
         results_dt_df_cv = pd.DataFrame(columns=['criterion', 'max_depth', 'min_samples_spli
         for params in params dt:
             clf = DecisionTreeClassifier(**params)
             cv_results = cross_validate(clf, X, y, cv=5, scoring=scoring)
             results_dt = {
                 'criterion': params['criterion'],
                 'max_depth': params['max_depth'],
                 'min_samples_split': params['min_samples_split'],
                 'min_samples_leaf': params['min_samples_leaf'],
                 'Accuracy': cv_results['test_accuracy'].mean(),
                 'Precision': cv_results['test_precision_weighted'].mean(),
                 'Recall': cv results['test recall weighted'].mean(),
                 'F1 Score': cv_results['test_f1_weighted'].mean()
             }
             results_dt_df_cv = results_dt_df_cv.append(results_dt, ignore_index=True)
         results_dt_df_cv.sort_values(by=['Accuracy', 'Precision'], ascending=False)
```

Out[]:		criterion	max_depth	min_samples_split	min_samples_leaf	Accuracy	F1 Score	Precision	Recal
	4	entropy	6	8	2	0.621152	0.605805	0.661620	0.621157
	5	gini	7	3	2	0.607309	0.586257	0.604215	0.607309
	6	gini	6	3	1	0.589037	0.565031	0.577741	0.58903
	0	entropy	7	3	1	0.579402	0.564768	0.598904	0.57940
	2	gini	7	3	1	0.565559	0.545539	0.570047	0.56555!
	3	gini	7	8	1	0.565449	0.542646	0.563046	0.565449
	1	gini	None	2	1	0.541971	0.526974	0.557442	0.54197

Out[ ]:	t[ ]: <b>Exp</b> e		var_smoothing	Accuracy	Precision	Recall	F1 Score	
	2	Without cv	7.390722e-04	0.534884	0.535153	0.534884	0.498368	
	0	Without cv	1.204504e-02	0.488372	0.435846	0.488372	0.408739	
	3	With cv	1.204504e-02	0.471982	0.390603	0.471982	0.389414	
	5	With cv	7.390722e-04	0.448505	0.411128	0.448505	0.396589	
	1	Without cv	1.000000e-09	0.441860	0.440476	0.441860	0.413577	
	4	With cv	1 000000e-09	0 345293	0 369824	0 345293	0 320733	

W przypadku klasyfikatora Bayesa walidacja krzyżowa nie przyniosła poprawy wyników, odstawała trochę od wyników bez jej użycia dla tego samego hiperparametru. Co ciekawe zmienił się ranking hiperparametru 'var\_smoothing' dla walidacji krzyżowej wystapiła inna ich kolejność w rankingu niż bez niej.

Out[ ]:		Experiment	criterion	max_depth	min_samples_split	min_samples_leaf	Accuracy	Precision	F
	0	Without cv	entropy	7	3	1	0.767442	0.810674	0.76
	3	Without cv	gini	7	8	1	0.767442	0.791724	0.76
	5	Without cv	gini	7	3	2	0.744186	0.795884	0.74
	6	Without cv	gini	6	3	1	0.744186	0.791412	0.74
	4	Without cv	entropy	6	8	2	0.744186	0.779623	0.74

	Experiment	criterion	max_depth	min_samples_split	min_samples_leaf	Accuracy	Precision	F
1	Without cv	gini	None	2	1	0.697674	0.662403	0.69
2	Without cv	gini	7	3	1	0.697674	0.638937	0.69
11	With cv	entropy	6	8	2	0.621152	0.661620	0.62
12	With cv	gini	7	3	2	0.607309	0.604215	0.60
13	With cv	gini	6	3	1	0.589037	0.577741	0.58
7	With cv	entropy	7	3	1	0.579402	0.598904	0.57
9	With cv	gini	7	3	1	0.565559	0.570047	0.56
10	With cv	gini	7	8	1	0.565449	0.563046	0.56
8	With cv	gini	None	2	1	0.541971	0.557442	0.54

W przypadku klasyfikatora drzewa decyzyjnego walidacja krzyżowa zajęła wszystkie miejsca w dolnej połowie rankingu - zdecydowanie nie poprawiła wyników. Kolejność zestawów parametrów jest inna niż bez walidacji krzyżowej.